



Mohammad Javad Ranjbar

810101173

Homework 1

Machine learning, Fall 2022

سوال ۱

محمد جواد زنجبیر ۸۱۰۱۰۱۷۳

تمرین سری اول یادگیری ماشین

سوال ۱

$$R(w_1|x) = \lambda_{11} P(w_1|x) + \lambda_{12} P(w_2|x) = \lambda_{12} P(w_2|x)$$

$$R(w_2|x) = \lambda_{21} P(w_1|x) + \lambda_{22} P(w_2|x) = \lambda_{21} P(w_1|x)$$

$$\lambda_{12} P(w_2|x) = \lambda_{21} P(w_1|x) \Rightarrow \lambda_{12} P(x|w_2) P(w_2) = \lambda_{21} P(x|w_1) P(w_1)$$

$$\frac{P(w_2)}{P(w_1)} = \frac{\lambda_{21}}{\lambda_{12}} \frac{P(x|w_2)}{P(x|w_1)} \Rightarrow \frac{\lambda_{12} P(w_2)}{\lambda_{21} P(w_1)} = \frac{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu_2)^2}}{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu_1)^2}}$$

$$\Rightarrow \ln\left(\frac{\lambda_{12} P(w_2)}{\lambda_{21} P(w_1)}\right) = -\frac{1}{2\sigma^2}(x-\mu_2)^2 - \left(-\frac{1}{2\sigma^2}(x-\mu_1)^2\right) \Rightarrow$$

$$-x^2 + 2\mu_2 x - \mu_2^2 + x^2 - 2\mu_1 x + \mu_1^2 = 2\sigma^2 \ln\left(\frac{\lambda_{12} P(w_2)}{\lambda_{21} P(w_1)}\right)$$

$$x(2\mu_2 - 2\mu_1) + (\mu_1^2 - \mu_2^2) \Rightarrow x = \frac{2\sigma^2 \ln\left(\frac{\lambda_{12} P(w_2)}{\lambda_{21} P(w_1)}\right) - (\mu_1^2 - \mu_2^2)}{2\mu_2 - 2\mu_1}$$

$$\xrightarrow{\mu_1=0, \mu_2=1} x = \frac{1}{2} - \sigma^2 \ln\left(\frac{\lambda_{12} P(w_2)}{\lambda_{21} P(w_1)}\right)$$

سوال ۲

سوال ۲ (ب)

$$P(\text{error}) = P(y \neq \hat{y}) = 1 - P(y = \hat{y}) = 1 - \sum_{i=1}^n P(x \in R_i, w_i) P(x \in R_i | w_i) P(w_i)$$

$$P(\text{error}) = 1 - \sum_{i=1}^n P(x \in R_i | w_i) P(w_i) = 1 - \sum_{i=1}^n \left(\int_{R_i} P(x | w_i) P(w_i) dx \right)$$

از آنجا که برای هر x کلاس وقتی انتخاب می‌شود که شانس آن کلاس بیشترین باشد به عبارتی کلاس انتخاب می‌شود که بیشترین $P(x | w_i) P(w_i)$ را داشته باشد. پس در عبارت بالا $P(x | w_i) P(w_i)$ بزرگترین عدد ممکن را خواهد داشت که در نتیجه $P(\text{error})$ با n کوچکترین حالت ممکن می‌باشد.

ب) از آنجا که $\sum_{i=1}^n P(w_i | x) = 1$ حداقل یک $P(w_i | x)$ باید موجود باشد که بزرگتر یا مساوی $\frac{1}{n}$ باشد و اگر این جمع یک نخواهد شد حال فرض می‌کنیم $P(w_k | x)$ نتیجه تصمیم باشد پس داریم که

$$P(w_k | x) = \max_i P(w_i | x) \text{ و با توجه به اینکه داریم } \frac{1}{n} \leq P(w_k | x) \text{ می‌توان نتیجه گرفت}$$

$$P(\text{error}) = 1 - \max_i P(w_i | x) \leq 1 - \frac{1}{n} = \frac{n-1}{n}$$

ج) ROC به صورت تابع برای درک مدل است. برای اینکه برای تعداد بیشتری کلاس (استانده کنیم) می‌توانیم از روش‌های one-vs-rest استفاده کنیم. به عبارتی هر بار می‌توانیم یک کلاس را با بقیه کلاس‌ها مقایسه کنیم. همچنین روش‌های دیگری مانند میانگین یک کلاس را بر روی همه یا با هم در نظر گرفتن تمام نتایج مثبت و منفی در یک کلاس نیز برای این کار مورد استفاده است.

د) خبر از ما می‌دهد همیشه نخواهد داشت. Naive Bayes در صورتی همیشه عمل خواهد کرد که ویژگی‌ها یا شرط کلاس از هم مستقل باشند (conditionally independent) حتی در اینجا فقط استقلال داده‌ای ویژگی‌ها ذکر شده است که لزوماً جواب همیشه نخواهد داشت مثلاً دو ویژگی A و B را کاملاً مستقل بگیریم و C کلاس باشد که داریم $A+B=C$ حال دیگر A باشد C از یک دیگر مستقل نیستند.

سوال ۳:

$$l(\mu) = \left(\prod_{i=1}^N P(x_i | \mu, \sigma^2) \right) P(\mu) \xrightarrow{L} \ln l(\mu) = \ln P(\mu) + \sum_{i=1}^N \ln P(x_i | \mu, \sigma^2)$$

$$\xrightarrow{P(\mu) = \frac{1}{\sigma^2 \sqrt{2\pi}} e^{-\frac{(\mu - \mu_0)^2}{2\sigma^2}}} L(\mu) = \ln \left(\frac{\mu e^{-\frac{\mu^2}{2\sigma^2}}}{\sigma^2} \right) + \sum_{i=1}^N \left(\ln \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left(\frac{x_i - \mu}{\sigma} \right)^2} \right) \right) \Rightarrow$$

$$L(\mu) = \ln(\mu) - \frac{\mu^2}{2\sigma^2} - \ln(\sigma^2) + \sum_{i=1}^N \left(\ln \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{(x_i - \mu)^2}{2\sigma^2} \right)$$

$$= \ln(\mu) - \frac{\mu^2}{2\sigma^2} - \ln(\sigma^2) + N \ln \left(\frac{1}{\sqrt{2\pi}\sigma} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^N (x_i - \mu)^2$$

حال برای حداکثر شدن نسبت به μ مشتق می گیریم و برابر صفر قرار می دهیم تا μ به دست آید:

$$\frac{dL}{d\mu} = \frac{1}{\mu} - \frac{\mu}{\sigma^2} - 0 + 0 + \frac{1}{\sigma^2} \sum_{i=1}^N (x_i - \mu) = 0 \xrightarrow{\times \mu}$$

$$\left(\frac{1}{\sigma^2} + \frac{\mu}{\sigma^2} \right) \mu - \left(\frac{1}{\sigma^2} \right) \left(\frac{1}{N} \sum_{i=1}^N x_i \right) \mu - 1 = 0$$

$$R = \frac{N}{\sigma^2} + \frac{1}{\sigma^2}, Z = \frac{1}{\sigma^2} \sum_{i=1}^N x_i \quad \text{حال داریم}$$

$$\Rightarrow R \mu^2 - Z \mu - 1 = 0 \Rightarrow \frac{-Z \pm \sqrt{Z^2 + 4R}}{2R} = \frac{Z}{2R} \left(1 \pm \sqrt{1 + \frac{4R}{Z^2}} \right)$$

که فقط جواب مثبت قابل قبول است

سوال ۴)

مسئله ۱۲

(الف)

$$P(n; p_i) = \prod_{j=1}^N p_i^{x_j} (1-p_i)^{1-x_j} \Rightarrow L(p_i) = \ln(P(n; p_i)) = \sum_{j=1}^N x_j \ln(p_i) + (1-x_j) \ln(1-p_i)$$


برای پیدا کردن تخمین ML نسبت به p_i مشتق میگیریم

$$\frac{\sum_{j=1}^N x_j}{p_i} - \frac{\sum_{j=1}^N (1-x_j)}{1-p_i} = 0 \Rightarrow -\frac{N}{1-p_i} + \sum_{j=1}^N x_j \left(\frac{1}{p_i} + \frac{1}{1-p_i} \right) = 0$$

$$\left(\frac{1-p_i + p_i}{p_i(1-p_i)} \right) \sum_{j=1}^N x_j = + \frac{N}{1-p_i} \Rightarrow \frac{1}{p_i} = \frac{N}{\sum_{j=1}^N x_j} \Rightarrow \hat{p} = \frac{1}{N} \sum_{j=1}^N x_j$$

ب) با نزدیک شدن \hat{p} به بی نهایت احتمال به p خواهد رفت و عبارت $\hat{p} = \frac{\sum x_i}{N} = \frac{p_d}{N}$ می توانیم مفاد سر صاف کنیم در نتیجه خواص خواهد شد

ج) مشخص است که با افزایش N مقدار \hat{p} نیز به p نزدیک و نزدیکتر خواهد شد و در صورتی که این توزیع نورمال داشته باشد شکل نهایی به صورت زیر خواهد بود




سوال ۵)

الف) قضیه بیز روشی برای محاسبه احتمالات شرطی ارائه می دهد که احتمال پسین نامیده می شود. که محتمل ترین فرضیه را که مجموعه داده آموزشی را توصیف می کند، پیدا می کند. Optimal baye یک مدل احتمالی است که محتمل ترین پیش بینی را با استفاده از داده های آموزشی و فضای فرضیه ها برای پیش بینی یک نمونه داده جدید پیدا می کند. در naïve bayes ما فرض بر conditional independence ویژگی ها می گذاریم یعنی برای هر ویژگی $P(X|Y,Z)=P(X|Z)$ برقرار است، اما در optimal bayes ویژگی ها ممکن است دارای وابستگی شرطی باشند.

ب)

با پیاده سازی naïve bayes، جدول زیر بدست می آید. که دارای درصدهای زیر می باشد:

```
Naive Bayes classification accuracy 0.9210526315789473
Precision score: 0.88
Recall score: 1.0
```




در کلاس ۰ داده های بیشتری موجود هستند و این مدل تعدادی از داده های دسته ی یک را به کلاس صفر نسبت داده است در حالی که هیچ داده ای از کلاس صفر به کلاس یک نسبت داده نشده است. در کل در این دیتاست اگر ۱ به معنی داشتن سرطان باشد، ماتریس بالا به شدت بد بوده زیرا ۹ نفر از کسانی که سرطان داشته اند به اشتباه نداشته اعلام شده اند.

پیاده سازی با کتابخانه:

```
Naive Bayes classification accuracy 0.9122807017543859
Precision score: 0.8961038961038961
Recall score: 0.971830985915493
```

که نتیجه دقیقاً مانند حالت بالاست.




ج) پیاده‌سازی بیزین آپتیمال امکان پذیر نیست، زیرا باید توزیع داده را به صورت دقیق داشته باشیم و رابطه‌ی بین ویژگی‌ها برای شخصی که علم ندارد نیز به راحتی قابل تشخیص نیست.

سوال ۶) هر عکس از سه ماتریس آبی، سبز، قرمز تشکیل شده است. حال می‌توان برای سادگی ویژگی‌های ماتریس را کم کرد و تنها میانگین اعداد هرکدام از این سه ماتریس را برای آموزش به مدل داد.

در اینجا از دو مدل استفاده کرده‌ایم یکی مدل naïve bayes که با استفاده از کتابخانه پیاده شده است و نتیجه زیر را می‌دهد:


```
Naive Bayes classification accuracy 0.88
Precision score: 0.9090909090909091
Recall score: 0.8333333333333334
```



که در این مورد خطای کلاس صفر که لیبل یک پیش‌بینی می‌کند زیاد است. از آنجا که این مدل برای دیتاست عکس فوتبال آموزش دیده است. این خطا زیاد موردی ندارد.

مدل دوم که به سادگی هرجا میانگین رنگ مربوط به تیم بالاتر بود آن تیم انتخاب می‌شود، نتیجه زیر را خواهد داد:

```
Color classification accuracy: 0.8442622950819673
Precision score: 0.76
Recall score: 0.9827586206896551
```



با وجود پاسخ نسبتاً مناسب این نوع پیاده سازی در عکس‌های موجود در دیتاست، برای عکس‌های نوع دیگر این روش قطعاً خطای بالایی خواهد داشت.